

Voice-based Image Retrieval

Whisper + CLIP 기반 음성 이미지 검색 시스템

Deep Learning Final Project

인공지능학과 202421718 박채원

ASR

Embedding

Retrieval

목차

01

Algorithm Overview

문제 정의 및 핵심 아이디어

02

Overall Pipeline

사용 모델과 각 단계의 입출력

03

Input & Final Output

음성 입력과 검색 결과

04

Implementation Details

데이터셋, 임베딩, 유사도 계산

05

Result & Limitation

실험 결과와 한계점

01 Algorithm Overview

음성 질의를 텍스트로 변환한 뒤, CLIP 임베딩 공간에서 관련 이미지를 검색

목표

- 사용자가 말한 문장을 이미지 검색 질의로 사용한다.
- 텍스트와 이미지를 같은 임베딩 공간으로 변환한다.
- Cosine similarity가 높은 이미지 Top-K를 최종 결과로 반환한다.

핵심 사용 모델

Whisper Tiny English	음성 파일을 영어 텍스트 질의로 변환
CLIP ViT-B/32	이미지와 텍스트를 공통 임베딩 공간으로 매핑

Step 1

Speech-to-Text

Whisper ASR
voice → text

Step 2

Multimodal Encoding

CLIP Encoders
text/image → vector

Step 3


Similarity Search

Cosine Similarity
vector → ranking

핵심 아이디어: 음성 인식 결과를 텍스트 검색어로 사용하고, CLIP의 멀티모달 표현학습을 활용해 관련 이미지를 찾는다.

02 Overall Pipeline

사용한 모델과 각 단계별 입출력



검색 단계에서는 정규화된 텍스트 임베딩과 사전 계산된 이미지 임베딩 간 cosine similarity를 계산하고, 유사도 점수를 기준으로 내림차순 정렬하여 Top-K 이미지를 반환한다.

03 Implementation Details

파이프라인의 각 단계에서 데이터가 변환되는 방식

단계	사용 모델/방법	입력	출력
1	Whisper Tiny English	query. m4a 사용자 음성 질의	텍스트 질의 "A cyclist riding a bike"
2	CLIP Text Encoder	Whisper가 변환한 문장	텍스트 임베딩 벡터
3	CLIP Image Encoder	Flickr8k 이미지 데이터셋	이미지 임베딩 벡터
4	Cosine Similarity	텍스트 임베딩 + 이미지 임베딩	유사도 점수 기반 Top-5 이미지

데이터셋 Flickr8k 일부 샘플을 사용하여 이미지 검색 후보군을 구성

검색 기준 CLIP 임베딩 간 cosine similarity가 높을수록 관련성이 높다고 판단

04 Input & Final Output

파이프실제 음성 질의 실행 결과

실험 입력

Voice Input: query.m4a


Recognized Text:
"A cyclist riding a bike"

Final Output:
Top-5 retrieved images

Recognized text: A cyclist riding a bike.

Query: A cyclist riding a bike.

	image_id	caption	score
37	flickr8k_00037.jpg	A bearded man wearing a bandanna is pointing h...	0.324744
5	flickr8k_00005.jpg	A cyclist wearing a red helmet is riding on th...	0.290011
346	flickr8k_00346.jpg	a biker performs a trick in the air .	0.283233
222	flickr8k_00222.jpg	A lady riding a mini motorcycle	0.275733
432	flickr8k_00432.jpg	A bicycler is riding a bike at a racing event .	0.268057



결과 : 음성 질의가 정확히 텍스트로 변환되었고, 자전거/라이딩 관련 이미지가 상위 검색 결과에 포함되었다.

05 Result & Limitation

구현 결과와 개선 가능성

구현 결과

- 음성 입력을 Whisper로 텍스트 변환
- CLIP 임베딩 기반 이미지 검색 구현
- Top-K 결과 시각화 및 확인

한계점

- CPU 환경으로 일부 데이터셋만 사용
- Zero-shot 방식이라 일부 결과는 완벽히 일치하지 않음
- 음성 품질에 따라 ASR 결과가 달라질 수 있음

개선 방향

- 더 큰 이미지 데이터셋 적용
- GPU 기반 임베딩 사전 계산
- 한국어 질의 처리 및 번역 모듈 추가

결론 : Whisper와 CLIP을 연결하여 음성 기반 이미지 검색의 전체 알고리즘 파이프라인을 구현하였다.